

人文社会ビジネス科学学術院 ビジネス科学研究群 2026年度 春C

テキストマイニングの実践 day 2

- URL: <https://github.com/haradatm/lecture-gssm2026>

注: 講義資料は、講義開始前まで更新する可能性があります。常に最新のスライドを確認するようにしてください。

①「**slides**」をクリックして開く

②「**day-N.pdf**」をクリックして開く

③ダウンロードボタン「↓」をクリック

lecture-gssm2026 / slides / day-1.pdf

10.7 MB

人文社会ビジネス科学学術院 ビジネス科学研究群 2025年度 春C
テキストマイニングの実践

スケジュール

day 1

- 講義(後半) — 自然言語処理とLLM

day 2

- 講義 — テキストマイニングの手順
- 講義&演習 — データ理解
- 講義&演習 — テキスト解析 (1)

day 3

- 講義&演習 — テキスト解析 (2)
- 講義&演習 — テキスト分析 (1)

day 4

- 講義&演習 — テキスト分析 (2)

day 5

- 演習 — テキスト分析 (発表会)
- 講義&演習 — LLMを用いたテキスト分析
- ラップアップ — Q&A

(前回) day 1 – レポート課題

- 以下を PDF ファイルで提出 してください
 - 社会人学生に役立つ、お薦めの生成AI(LLMやテキストマイニング以外も可)と使い方を教えてください
- ※ 何らかの事情で上記を提出できない場合、本日の講義の感想を文章で記述してください

レポート形式	提出先	期限
PDF	manaba	次回～18:20

業務効率化・自動化	・ 議事録の自動作成・要約: 会議の音声データから自動で文字起こしを行い、要点をまとめた議事録を作成する ・ 問い合わせ対応の自動化: FAQやマニュアルを学習させ、社内外からの問い合わせに自動で回答するチャットボットを構築する ・ 文章の校正・翻訳: 作成した文章の誤字脱字チェックや、より適切な表現への修正、多言語への翻訳を瞬時に行う ・ 社内文書の検索と要約: 社内の膨大な規定やマニュアルの中から、必要な情報を探し出し、要約して提示させる ・ 採用業務の効率化: 応募者のエントリーシートをAIが分析・評価し、面接官の負担を軽減する
コンテンツ制作	・ マーケティングコンテンツの生成: 広告のキャッチコピー、SNS投稿文、メルマガなど、ターゲットに合わせた文章を複数パターン生成する ・ 資料作成の支援: プレゼンテーションの構成案作成、スライドの文章やデザイン案の生成をサポートさせる ・ アイデア創出(ブレインストーミング): 新規事業や企画のアイデア出しの壁打ち相手として活用し、多様な視点を導く ・ デザイン・画像生成: ロゴ、バナー、イラストなど、コンセプトを伝えるだけでデザイン案を複数作成させる
専門業務の支援	・ ソフトウェア開発: プログラムコードの自動生成、レビュー、デバッグ作業を支援させ、開発スピードを向上させる ・ 教育・研修: 個人の理解度や職種に合わせた研修コンテンツやテスト問題を自動生成し、個別最適な学習を提供する ・ 法務・契約業務: 契約書のドラフト作成や、不利な条項がないかのリーガルチェックを支援させる

1. 文章生成・要約・翻訳

ツール・サービス名	登場回数
ChatGPT	6
Gemini	3
Copilot	2
Claude	2
NotebookLM	2
自治体 AI zevo	1
Readable	1
Cedric	1
DeepL	1
Google翻訳	1
Grammarly	1

2. 情報収集・調査

ツール・サービス名	登場回数
Consensus	1
Connected Papers	1
Scholar AI	1
Perplexity	1

3. 資料作成・プレゼンテーション

ツール・サービス名	登場回数
Mapify	3
Canva AI	1
イルシル	1
Gamma	1

4. プログラミング・開発

ツール・サービス名	登場回数
Cursor	2
Mastra AI	1
OpenAI BatchAPI	1

5. 音声・動画処理

ツール・サービス名	登場回数
Gladia	1
Otter	1

6. その他

ツール・サービス名	登場回数
Slack AI	1
Box AI	1
Google Drive OCR	1

参考 — 生成AI活用アイデア（7/2時点の26件分で集計）

ツール	主な用途	使い方の例	報告数
ChatGPT	汎用支援、壁打ち、構成、検索、校正	論文検索、研究テーマ相談、レポート構成、文章修正、英会話練習	12
Gemini	検索、理解補助、画像生成、コード補助	難解な内容の噛み砕き、概念図作成、Pythonコード生成、壁打ち	9
NotebookLM	資料読解、要約、比較、スライド化	論文PDFの要約、講義資料理解、複数論文比較、図解/スライド作成	9
DeepL	翻訳、英文校正	英語論文読解、英文メール修正、自然な翻訳表現の確認	5
Claude	文章生成、文章の自然さ、構成支援	自然な文章作成、文章添削、構成整理	4
Microsoft Copilot	要約、文書補助、業務活用	報告書・議事録の横断要約、調査、文書草稿	3
Perplexity	情報収集、論文探索	関連研究や外部情報の収集、出典付き調査	3
Claude Code	コーディング、コードベース探索	ターミナルでの実装支援、コンテキスト可視化、反復作業	2
Codex	コーディング、実装支援	Claude Code と組み合わせた実装分担、コード修正	2
Notion AI	タスク管理	授業・課題の管理支援	2
Cursor	レポート/スライド/ノート整理補助	高頻度・反復的な作業の効率化	1
Elicit	論文探索、研究支援	先行研究の検索、論文ベースの調査	1
Gamma	スライド作成	発表資料のドラフト作成	1
Genspark	情報収集、論文探索	論文や関連情報の探索支援	1
Motion	スケジュール最適化	仕事・家庭・学業をまたぐ予定調整への期待	1
Napkin AI	図解作成	文章から洗練された図解を短時間で作る	1

(参考) [PLaMo 翻訳](#) : 1か月5万文字まで無料

参考 — 生成AI活用アイデア（7/2時点の26件分で集計）

No.	どのように使っているか
1	Claude Code と Codex をターミナルで併用し、Geminiで概念図・模式図を生成。grill-me を Claude Skills に登録して認識合わせを行う
2	論文探索に ChatGPT/Copilot/Perplexity/Elicit、図生成に Gemini、英文校正に DeepL、文章支援に Claude、タスク管理に Notion AI を使い分ける
3	NotebookLMで論文の概要把握、ChatGPT Plusで先行研究調査や仮説相談、GeminiでColab上のPythonコード生成やエラー修正
4	Geminiの長いコンテキストを活かして研究支援に使い、ChatGPTやClaudeとも比較しながら活用
5	Geminiで難しい授業内容を平易に理解し、NotebookLMで論文や決算書の要点を素早くつかむ
6	文書校正、翻訳、文書(契約書)のドラフト、調査、アイデアの壁打ち等々
7	テキストからフローチャート、比較表、概念図を自動生成し、発表資料の図解作成を効率化
8	仕事と学業を両立する中で、講義資料や論文の理解を深める用途として推奨
9	ChatGPT Proで論点整理や資料構成、Codex CLIでローカルのファイル・コード修正。方針やルールを md に明記して一貫運用
10	Excel上でデータ集計・統計分析を効率化し、講義課題や不明点の質問、アイデア壁打ち、知識取得に活用
11	ChatGPTを学習や研究の対話型アドバイザーとして使い、研究背景や目的、先行研究との差分整理に活用
12	事例を探して比較表作成に必要な情報を質問しながら埋め、未知分野では基礎知識や用語を確認
13	今回の抽出ログでは本文要点の取得が不十分で、個別用途の確定ができていない
14	現在利用というより利用意向。自分が集めた論文の整理や理解支援に使いたいとしている
15	Geminiで不明点検索、NotebookLMで要約による理解確認、DeepLで英語論文を読む
16	文書校正、謝罪・指導メール調整、海外向けメール翻訳、会議録音から議事録草稿作成、人事・法務文書の校正
17	Cursorで授業ノート・レポート・スライド作成を反復支援し、writing-skill slides-design-skill coding-skill を管理。Claude Codeで paper-map 開発
18	論文PDFを読み込ませて要約・図解化し、類似論文3本の共通点/相違点を整理。ChatGPTで重要論文候補を調べる
19	レポートの文章構成や表現修正案を出させ、自分で加筆修正。講義との関連づけや計算確認にも使う
20	手元資料を添付し、ネット検索ではなく資料ベースで構成や重要論点を把握するために使う
21	アイデア整理、文章要約、スライド作成、情報収集、翻訳、タスク管理を用途ごとにツール分担している
22	レポート文体への修正、課題に対する反論出し、Excelデータの傾向説明やグラフ案検討、研究テーマに関する学術的議論の把握に使っている。
23	仕事ではGeminiでPython/SQLのエラー分析、私用ではChatGPTで誤字脱字確認。各AIの得意分野を比較している
24	Copilotで複数年度資料を横断要約し、ChatGPTでは英語論文を題材に英会話練習を行う
25	複数AIを比較利用し、Claudeの言語能力、NotebookLMのRAG活用を評価。AIに学び方を提案させ、成果物を採点させる
26	論文内容の壁打ちはNotebookLM、雑多な疑問や構造化はGeminiに分担。各スライドが伝わるかAIに要約させて確認

テキストマイニングの手順

- 驚異的な大量の文書データに記述されている多種多様な内容を対象として、その相関関係や出現傾向などから新たな知識を発見する [那須川,1999]
- 市場調査や販売戦略の立案, 製品やサービス改善、顧客対応の改善に役立てたい
 - アンケート、**ソーシャルメディア**(レビューサイトのクチコミやツイート) など
- 報道番組などで **X (旧Twitter)** 分析を取り上げることも多い
 - 新型コロナウイルス、震災、選挙など

ソーシャルメディアをめぐる環境の変化

- X(旧Twitter)は、いまだに日本のソーシャルメディアにおいて大きな影響力
→ データ購入が高額化し、研究が難しくなっている




図 5-1-2 【令和 7 年度】主なソーシャルメディア系サービス/アプリ等の利用率(書き込む・投稿する)
出典: 総務省「令和7年度情報通信メディアの利用時間と情報行動に関する調査報告書」

出典: [鳥海'26] JSAI2026 チュートリアル4「ソーシャルメディアの分析手法」の講演をもとに作成

ソーシャルメディアをめぐる環境の変化

- X以外のソーシャルメディア
 - Facebook/Instagram/TikTok →データアクセスが困難
 - YouTube/Reddit のデータを活用した研究が盛ん
例) フェイクニュースやプロパガンダ研究
 - [YouTube Researcher Program](#) によるアクセス緩和措置あり
 - ただし、申請や審査に時間がかかるため、研究室単位の契約を推奨とのこと
- Bluesky: Xの代替として期待
 - フォローやLike 豊富なデータが無申請・無料で取得可能
 - ただし、そもそもメディア利用が低調

(参考) [鳥海先生の ERATOプロジェクト](#)

- プロジェクト参加者(+謝辞記載)して、Xデータを利用する
 - 日本語10%サンプル (2026年4月以降)
 - 研究発表等にあたり、NTTデータ/X社の事前確認あり
 - 偽情報・フェイクニュース関係の研究発表は困難
- Xのヒストリカルデータ分析環境
 - 過去1年分の日本語ツイートから検索
 - 研究発表等にあたり、NTTデータ/X社の事前確認あり
- Xの新規データ
 - 100万件/月のPro契約、Pay-Per-Use契約 が利用可能

出典: [鳥海'26] JSAI2026 チュートリアル4「ソーシャルメディアの分析手法」の講演をもとに作成

(参考) [Xのコミュニティノート](#)

- Xの投稿に対して、他のユーザーが補足説明や背景情報を付けられる機能
 - 誤解を招きそうなポストに、正しい情報や前提となる文脈を補足するのが目的
 - 多くのユーザーから「役に立つ」と評価されると、その投稿にと一緒に表示
 - 書かれた補足説明がすぐに表示されるわけではない
- コミュニティノートは透明性のため、[すべてのデータ\(5種類\)が公開](#)

Note: ノートの作成者、テキスト内容、評価状態

Rating: 各ユーザの評価のデータ

Note status history: ノートの評価の時間変化

User: 参加ユーザーの詳細データ

Request: ノートのリクエストのデータ

分析例:

地震、ワクチン、
特殊詐欺、
政治・選挙

クチコミサイトの例 — 楽天トラベル

- ホテルのクチコミ数: 1,635万件 ※ 2026/5/9現在

The screenshot shows the Rakuten Travel website interface. At the top, there's a navigation bar with links like 'ヘルプ', 'ご利用ガイド', 'サイトマップ', 'Language', '楽天市場', and '楽天グループ'. Below this is the 'Rakuten Travel' logo and a user profile section for '原田 智彦さん' with 18 points and 'Bonus レベル 0'. A banner for 'ホテル・旅館・高速バスのクチコミ' (Hotel, Inn, and Expressway Bus Reviews) features the text 'お客様の声' (Voice of the Customer) and a large number '16,347,341' representing the number of reviews. Below the banner is a search bar for reviews, with filters for '国内' (Domestic) and '海外' (Overseas). The main content area displays a list of reviews under the heading '新着! 最新のクチコミ' (New! Latest Reviews), with a date of '2026年5月 09日 更新'. The list shows two reviews for 'ホテル富士トリエートのクチコミ' (Hotel Fuji Triet) and 'リバーサイドホテル松栄のクチコミ' (Riverside Hotel Matsuoka). A sidebar on the right promotes the 'お客様の声' feature, stating that it contains actual user opinions and experiences.

ホテルのクチコミ・お客様の声 × + Gemini に相談

travel.rakuten.co.jp/review/ Google で調べる

ヘルプ ご利用ガイド サイトマップ Language 楽天市場 楽天グループ

Rakuten Travel

お気に入り 予約確認 ログアウト メニュー エントリー & 初めて使うごとに最大 6,000 ポイント GET!

原田 智彦さん 18 ポイント Bonus レベル 0 > 国内宿泊がポイント1% > 特別ご招待

国内宿泊 交通+宿 レンタカー 高速バス・ツアー 海外旅行 遊び・体験 キャンプ場 割引クーポン ふるさと納税 旅行ガイド その他

ホテル・旅館・高速バスのクチコミ

お客様の声

ホテルのクチコミ数No.1 16,347,341

お客様アンケート回答数

家族で楽しめました 素敵なお部屋でした 食事が最高においしかった!

クチコミ (お客様の声) を検索 国内宿泊 海外ホテル 検索

国内 すべてが最高 また来たい プロポーズ 肌 つるつる アメニティ 持ち帰り 海外 景色 最高 イケメン 日本語

新着! 最新のクチコミ 2026年5月 09日 更新

国内宿泊 海外ホテル

2026-05-08 23:59:06 ホテル富士トリエートのクチコミ (6件) 3.33

2026-05-08 23:57:49 リバーサイドホテル松栄のクチコミ (459件) 3.83

「お客様の声」には、実際にご利用になった方のご意見・ご感想が満載です。

国内宿泊 高速バス ペットホテル 海外ホテル

R 鴨川シーワールドホテル に実際に

Gemini に相談

travel.rakuten.co.jp/HOTEL/2910/review.html

Rakuten Travel

原田 智彦さん9ポイント Bonus レベル0 > 国内宿泊がポイント1% > 特別ご招待

国内宿泊 交通+宿 レンタカー 高速バス・ツアー 海外旅行 遊び・体験 キャンプ場 割引クーポン ふるさと納税 旅行ガイド その他

楽天トラベルトップ > 全国 > 千葉県 > 鴨川・勝浦・御宿・養老浜谷 > 鴨川温泉 > 鴨川シーワールドホテルのクチコミ

鴨川シーワールドホテル

★★★★★ 4.29 (3,495件) | 〒296-0041 千葉県 鴨川市東町1464-18

ふるさと納税対象

施設紹介 宿ニュース プラン一覧 部屋一覧 写真・動画(53) 地図・アクセス お客さまの声(3,495) クーポン一覧

クチコミ

総合評価 4.29 3,495件

★5 1,002件
★4 1,316件
★3 275件
★2 56件
★1 35件

部屋 3.95 接客・サービス 4.42 ロケーション 4.62 朝食 4.16 夕食 4.13 温泉・お風呂 3.80 設備 3.81 清潔さ 4.10

絞り込み おすすめ▼

クチコミを検索する

検索

クチコミの投稿画像・動画

2,863件

★★★★★ 5 レジャー | 家族 | 2026年5月宿泊

40代/男性 | 15件のクチコミ

2026年5月25日投稿

鰐の寿司🍣とオーシャンビュー最高！
夕飯のバイキングで鰐を目の前で捌いてお寿司の提供🍣美味しすぎた
その他の料理も満足できました
二日間鴨川シーワールド入場券も付いていて、二日間楽しんできました
ホテルは築年数から古さも感じ取れましたが、館内は清潔、衛生的で大満足でした
全室オーシャンビュー!!
部屋から海を眺めゆっくりいられた時間最高でした

部屋: 3 | 接客・サービス: 5 | ロケーション: 5 | 朝食: 5 | 夕食: 5 | 温泉・お風呂: 5 | 設備: 4 | 清潔さ: 5
追加情報: 小さな子供と一緒に宿泊

R 鴨川シーワールドホテル に実際に

Gemini に相談

travel.rakuten.co.jp/HOTEL/2910/review.html

施設紹介 宿ニュース プラン一覧 部屋一覧 写真・動画(53) 地図・アクセス お客さまの声(3,495) クーポン一覧

部屋: 3 | 接客・サービス: 5 | ロケーション: 5 | 朝食: 5 | 夕食: 5 | 温泉・お風呂: 5 | 設備: 4 | 清潔さ: 5
追加情報: 小さな子供と一緒に宿泊

宿泊プラン 2026年4月～【30日前までの予約】1 早めに決めてお得★さきさきプラン
部屋タイプ 禁煙和室海側

👍 👁 67

不適切なクチコミを報告する

この度は、当館をご利用頂き誠にありがとうございます。
当館は鴨川シーワールドのオフィシャルホテルとして、利便性に好感頂き嬉しく思います。
そして、滞在中無料でご利用可能です。
建物は、築50年を経過しますので古さは否めませんが、お客様が快適にお過ごし頂けるように助んでおります。
また、お食事について概ね評価頂き大変うれしく思います。
夕食では、オープンキッチンによるローストビーフの切りたて・天婦羅の揚げたて・さばいた「ぶり」の握りたての館など、3
たてで皆様にお楽しみ頂いております。
最後に「部屋から海を眺めゆっくりいられた時間最高でした」との感想は、全スタッフで共有し励みとさせていただきます。
客室は全てオーシャンビューで雄大な太平洋が眼下に広がります。
今後も、更なる努力と工夫を重ねサービスの向上を目指して参ります。
また鴨川へお越しの機会がございましたらご利用をお待ちしております。
ありがとうございました。
鴨川シーワールドホテル
2026-05-28
閉じる

★★★★★ 5 レジャー | 家族 | 2026年5月宿泊

60代/女性 | 49件のクチコミ

2026年5月19日投稿

何度行っても、シーワールドの魅力で癒されるので、便利なホテルの宿泊に助かります！
確かに少し古いですが、部屋の空調も新しくなり、ビュッフェは相変わらずメニュー多彩で楽しめました！また近いうちにお邪魔
します！

部屋: 4 | 接客・サービス: 5 | ロケーション: 5 | 朝食: 5 | 夕食: 5 | 温泉・お風呂: 4 | 設備: 4 | 清潔さ: 5
追加情報: 高齢者と一緒に宿泊

宿泊プラン 2026年4月～いい値！バリュプラン
部屋タイプ 最上階禁煙 禁煙和室10畳

👍 👁 130

不適切なクチコミを報告する

いつも当館をご利用頂き誠にありがとうございます。

R08年度 01KA438, 0ADM126

テキストマイニング

79

鴨川シーワールドホテル

★★★★★ 4.29 (3,495件) > | 296-0041 千葉県 鴨川市東町1464-18



🏠 ふるさと納税対象

施設紹介 | 宿ニュース | プラン一覧 | 部屋一覧 | 写真・動画(53) | 地図・アクセス | **お客さまの声(3,495)** | クーポン一覧


クチコミ

総合評価

4.29



3,495件



部屋

3.95



接客・サービス

4.42



ロケーション

4.62



朝食

4.16



夕食

4.13



温泉・お風呂

3.80



設備

3.81



清潔さ

4.10


施設の総合評価
(数値評価)

★★★★★ 5

レジャー | 家族 | 2026年5月宿泊



40代/男性 | 15件のクチコミ



鯨の寿司🐟とオーシャンビュー最高！

2026年5月25日投稿

夕飯のバイキングで鯨を目の前で捌いてお寿司の提供🍣美味しすぎた
その他の料理も満足できました
二日間鴨川シーワールド入場券も付いていて、二日間楽しんできました
ホテルは築年数から古さも感じ取れましたが、館内は清潔、衛生的で大満足でした
全室オーシャンビュー!!
部屋から海を眺めゆっくりしていられた時間
最高でした

テキストデータ

数値評価

部屋: 3 | 接客・サービス: 5 | ロケーション: 5 | 朝食: 5 | 夕食: 5 | 温泉・お風呂: 5 | 設備: 4 | 清潔さ: 5

- データを理解する
 - データ件数や構成比を集計 → 対象データに詳しくなる
 - 投稿者の属性(年齢、性別)の分布は?
 - 旅行目的や同伴者別の分布は?
 - 目的別やエリア別の数値評価の傾向は? (→数値評価は結果系)
- テーマを設定する
 - 解決すべき課題を決める → 分析目的を明確にする
 - 数値評価が低い原因は?
 - 高評価の施設に学ぶ改善点は?
- テキスト分析に取り組む
 - これら課題を解決するために、テキスト分析を実施 (→テキストは原因系)

- データを理解する
 - データ件数や構成比を集計 → 対象データに詳しくなる
 - 投稿者の属性(年齢、性別)の分布は?
 - 旅行目的や同伴者別の分布は?
 - 目的別やエリア別の数値評価の傾向は? (→数値評価は結果系)
- テーマを設定する
 - 解決すべき課題を決める → 分析目的を明確にする
 - 数値評価が低い原因は?
 - 高評価の施設に学ぶ改善点は?
- テキスト分析に取り組む
 - これら課題を解決するために、テキスト分析を実施 (→テキストは原因系)

データ理解

- 楽天トラベル のクチコミデータ
 - 収集期間は 2023-2024 および 2025-2026(~GW明け) の 2セット
 - 以下の 10 エリアごと同数に 1,000件ずつ ランダムサンプリング
 - データ件数は 1万件 × 2セット



レジャー	5エリア	登別、草津、箱根、道後、湯布院	1,000件 × 10エリア = 計10,000件
ビジネス	5エリア	札幌、名古屋、東京、大阪、福岡	

実習用のデータ (Webサイトクロール)

- 楽天トラベル のクチコミデータ
 - 収集期間は 2023-2024 および 2025-2026(~GW明け) の 2セット
 - 以下の 10 エリアごと同数に 1,000件ずつ ランダムサンプリング
 - データ件数は 1万件 × 2セット
 - データ項目は 21項目 (テキスト2項目+その他の属性19項目)

施設情報	5項目	カテゴリ, エリア, 施設番号, 施設名, レビュー数
口コミ	2項目	レビュータイトル (テキスト), レビュー本文 (テキスト)
ユーザー評価	8項目	部屋, 接客・サービス, ロケーション, 朝食, 夕食, 温泉・お風呂, 設備, 清潔さ
その他の分類	2項目	旅行の目的, 同伴者
宿泊日	1項目	宿泊年月
ユーザー情報	4項目	年代, 性別, 投稿数, ニックネーム

● クチコミの件数と感染者数の増減が連動 → クチコミ件数が一定の人流を反映している




実習用データ — ファイル一覧

- 実習用データは以下の通り →主に「**rakuten-1000-2025-2026.xlsx**」を使用する

ファイル名	件数 (サイズ)	データセット	備考
rakuten-1000-2025-2026.xlsx.zip	10,000 (2.8 MB)	- レジャー+ビジネスの 10エリア - エリアごと 1,000件 (ランダムサンプリング) - 期間: 2025/1~2026 GW明け	本講義の全体を通して使用する
rakuten-1000-2023-2024.xlsx.zip	10,000 (2.8 MB)	- レジャー+ビジネスの 10エリア - エリアごと 1,000件 (ランダムサンプリング) - 期間: 2023/1~2024/12	演習用 (年度で比較する場合など)
rakuten-all-2025-2026-tsv.zip	174,888 (23 MB)	- レジャー+ビジネスの 10エリア - サンプリング前の全データ - 期間: 2025/1~2026 GW明け	参考用
rakuten-all-2023-2024-tsv.zip	171,163 (21 MB)	- レジャー+ビジネスの 10エリア - サンプリング前の全データ - 期間: 2023/1~2024/12	参考用
rakuten-all-tsv.zip	1,720,202 (233 MB)	- レジャー+ビジネスの 10エリア - サンプリング前の全データ - 期間: 2009/3~2024 GW明け	参考用

参考 — Google Drive ダウンロード画面




ここをクリックすると
ダウンロードが始ま
ります


- EXCEL のピボットテーブルを使ってデータを集計する

- ① ファイル **rakuten-1000-2025-2026.xlsx** を開く
- ② A～X 列を選択し、ピボットテーブルを作成する
- ③ [挿入] タブ [テーブル] グループの [ピボットテーブル] ボタンをクリックする

Windows



Mac



①件数 (エリア別)

行ラベル	個数 / 施設数
☐A_レジャー	5000
01_登別	1000
02_草津	1000
03_箱根	1000
04_道後	1000
05_湯布院	1000
☐B_ビジネス	5000
06_札幌	1000
07_名古屋	1000
08_東京	1000
09_大阪	1000
10_福岡	1000
総計	10000

②投稿者の傾向 (年代別x性別)

個数 / 施設数	列ラベル			
行ラベル	男性	女性	(空白)	総計
10代	0.06%	0.15%	0.00%	0.21%
20代	2.10%	3.25%	0.00%	5.35%
30代	4.42%	5.65%	0.00%	10.07%
40代	7.97%	7.84%	0.00%	15.81%
50代	12.84%	8.87%	0.00%	21.71%
60代	9.37%	4.23%	0.00%	13.60%
70代	2.10%	0.61%	0.00%	2.71%
80代~	0.12%	0.05%	0.00%	0.17%
(空白)	0.00%	0.00%	30.37%	30.37%
総計	38.98%	30.65%	30.37%	100.00%

③投稿者の傾向 (性別xカテゴリ別)

個数 / 施設数	列ラベル		
行ラベル	A_レジャー	B_ビジネス	総計
男性	37.46%	40.50%	38.98%
女性	33.48%	27.82%	30.65%
(空白)	29.06%	31.68%	30.37%
総計	100.00%	100.00%	100.00%

④投稿者の傾向（性別xカテゴリ-エリア別）

個数 / 施設番号		列ラベル										B_ビジネス 集計	総計
		A_レジャー					B_ビジネス						
行ラベル	01_登別	02_草津	03_箱根	04_道後	05_湯布院	A_レジャー 集計	06_札幌	07_名古屋	08_東京	09_大阪	10_福岡		
男性	40.60%	35.00%	30.80%	44.60%	36.30%	37.46%	41.70%	42.80%	41.10%	36.30%	40.60%	40.50%	38.98%
女性	32.60%	34.50%	36.60%	26.50%	37.20%	33.48%	27.10%	25.60%	29.40%	29.60%	27.40%	27.82%	30.65%
(空白)	26.80%	30.50%	32.60%	28.90%	26.50%	29.06%	31.20%	31.60%	29.50%	34.10%	32.00%	31.68%	30.37%
総計	100.00%	100.00%	100.00%	100.00%	100.00%	100.00%	100.00%	100.00%	100.00%	100.00%	100.00%	100.00%	100.00%

⑤投稿者の傾向（年代別xカテゴリ-エリア別）

個数 / 施設番号		列ラベル										B_ビジネス 集計	総計
		A_レジャー					B_ビジネス						
行ラベル	01_登別	02_草津	03_箱根	04_道後	05_湯布院	A_レジャー 集計	06_札幌	07_名古屋	08_東京	09_大阪	10_福岡		
10代	0.00%	0.90%	0.20%	0.10%	0.30%	0.30%	0.00%	0.10%	0.30%	0.10%	0.10%	0.12%	0.21%
20代	4.10%	9.40%	9.10%	4.60%	7.00%	6.84%	3.80%	2.30%	4.00%	4.60%	4.60%	3.86%	5.35%
30代	9.90%	9.00%	11.50%	7.90%	11.20%	9.90%	10.40%	9.60%	10.00%	9.90%	11.30%	10.24%	10.07%
40代	15.30%	13.40%	14.60%	15.20%	16.80%	15.06%	15.40%	17.60%	18.30%	16.80%	14.70%	16.56%	15.81%
50代	24.70%	18.80%	15.60%	22.50%	20.50%	20.42%	23.60%	24.10%	23.20%	20.60%	23.50%	23.00%	21.71%
60代	16.00%	15.10%	12.10%	16.90%	14.80%	14.98%	12.80%	12.70%	12.20%	11.50%	11.90%	12.22%	13.60%
70代	3.10%	2.50%	3.80%	3.90%	2.90%	3.24%	2.60%	1.90%	2.20%	2.30%	1.90%	2.18%	2.71%
80代～	0.10%	0.40%	0.50%	0.00%	0.00%	0.20%	0.20%	0.10%	0.30%	0.10%	0.00%	0.14%	0.17%
(空白)	26.80%	30.50%	32.60%	28.90%	26.50%	29.06%	31.20%	31.60%	29.50%	34.10%	32.00%	31.68%	30.37%
総計	100.00%	100.00%	100.00%	100.00%	100.00%	100.00%	100.00%	100.00%	100.00%	100.00%	100.00%	100.00%	100.00%

⑥ 投稿者の傾向（同行者別xカテゴリ-エリア別）

個数 / 施設番号		列ラベル										A_レジャー 集計	B_ビジネス 集計	B_ビジネス 集計	総計
		A_レジャー													
行ラベル		01_登別	02_草津	03_箱根	04_道後	05_湯布院		06_札幌	07_名古屋	08_東京	09_大阪	10_福岡			
家族		68.50%	66.00%	70.80%	44.90%	69.40%		38.44%	26.60%	25.93%	39.40%	34.40%	32.95%	48.44%	
一人		21.50%	13.70%	11.30%	44.60%	12.30%		50.55%	65.10%	66.07%	49.20%	56.10%	57.40%	39.04%	
友達		3.60%	7.40%	7.50%	4.30%	6.80%		5.81%	3.50%	3.20%	6.60%	4.00%	4.62%	5.27%	
恋人		4.40%	12.10%	9.20%	3.40%	9.60%		2.70%	2.70%	2.50%	3.40%	2.20%	2.70%	5.22%	
仕事仲間		1.70%	0.30%	0.80%	2.60%	0.80%		1.90%	1.60%	1.90%	1.20%	2.70%	1.86%	1.55%	
その他		0.30%	0.50%	0.40%	0.20%	1.10%		0.60%	0.50%	0.40%	0.20%	0.60%	0.46%	0.48%	
総計		100.00%	100.00%	100.00%	100.00%	100.00%		100.00%	100.00%	100.00%	100.00%	100.00%	100.00%	100.00%	

⑦ 数値評価の構成（接客・サービス）

接客・サービス

個数 / 施設番号	列ラベル													A_レジャー 集計	B_ビジネス 集計	B_ビジネス 集計	総計
行ラベル	01_登別	02_草津	03_箱根	04_道後	05_湯布院	06_札幌	07_名古屋	08_東京	09_大阪	10_福岡							
5	47.30%	56.80%	53.90%	49.70%	70.50%	55.64%	44.90%	42.70%	43.60%	45.40%	40.30%	43.38%	49.51%				
4	32.10%	26.90%	28.00%	30.20%	18.80%	27.20%	33.40%	33.90%	33.30%	30.90%	35.80%	33.46%	30.33%				
3	14.20%	11.90%	12.00%	14.90%	7.80%	12.16%	17.40%	19.50%	17.20%	18.80%	18.30%	18.24%	15.20%				
2	3.80%	2.30%	3.00%	3.30%	2.10%	2.90%	2.50%	2.40%	3.40%	3.40%	3.50%	3.04%	2.97%				
1	2.60%	2.10%	3.10%	1.90%	0.80%	2.10%	1.80%	1.50%	2.50%	1.50%	2.10%	1.88%	1.99%				
総計	100.00%	100.00%	100.00%	100.00%	100.00%	100.00%	100.00%	100.00%	100.00%	100.00%	100.00%	100.00%	100.00%				

⑧-a 数値評価の平均 (エリア別x数値評価別)

行ラベル	平均 / 総合評	平均 / 部屋	平均 / 接客・サ	平均 / ロケーシ	平均 / 朝食	平均 / 夕食	平均 / 温泉・お	平均 / 設備	平均 / 清潔さ
☐A_レジャー	4.32	4.19	4.31	4.26	4.36	4.41	4.32	4.10	4.25
01_登別	4.20	4.00	4.18	4.21	4.18	4.22	4.31	3.96	4.05
02_草津	4.30	4.18	4.34	4.27	4.34	4.36	4.35	4.08	4.29
03_箱根	4.33	4.23	4.27	4.18	4.35	4.39	4.29	4.09	4.20
04_道後	4.25	4.11	4.23	4.24	4.33	4.49	4.16	4.03	4.21
05_湯布院	4.52	4.46	4.56	4.38	4.59	4.63	4.47	4.34	4.49
☐B_ビジネス	4.19	4.11	4.13	4.24	4.16	4.53	3.88	3.97	4.18
06_札幌	4.25	4.19	4.17	4.27	4.22	4.85	3.90	4.02	4.27
07_名古屋	4.16	4.10	4.14	4.18	4.11	3.70	3.89	3.96	4.15
08_東京	4.17	4.10	4.12	4.26	4.09	5.00	3.84	3.95	4.09
09_大阪	4.25	4.18	4.15	4.32	4.25	4.29	3.99	4.02	4.29
10_福岡	4.12	4.00	4.09	4.16	4.10	4.67	3.77	3.89	4.15

⑧-b 数値評価の平均 (カテゴリ別x数値評価別)

行ラベル	平均 / 総合評	平均 / 部屋	平均 / 接客・サ	平均 / ロケーシ	平均 / 朝食	平均 / 夕食	平均 / 温泉・お	平均 / 設備	平均 / 清潔さ
A_レジャー	4.32	4.19	4.31	4.26	4.36	4.41	4.32	4.10	4.25
B_ビジネス	4.19	4.11	4.13	4.24	4.16	4.53	3.88	3.97	4.18

⑨-a 数値評価の平均
(20~30代, 性別)

行ラベル	平均 / 総合評価	平均 / 部屋	平均 / 接客・サービス	平均 / ロケーション	平均 / 朝食	平均 / 夕食	平均 / 温泉・お風呂	平均 / 設備	平均 / 清潔さ
☐A_レジャー	4.36	4.38	4.46	4.37	4.48	4.50	4.42	4.31	4.35
女性	4.39	4.44	4.52	4.44	4.49	4.51	4.47	4.41	4.40
男性	4.32	4.30	4.38	4.26	4.46	4.48	4.37	4.18	4.27
☐B_ビジネス	4.20	4.23	4.32	4.27	4.33	4.83	4.05	4.11	4.26
女性	4.24	4.27	4.39	4.30	4.44	4.75	4.04	4.14	4.29
男性	4.16	4.17	4.23	4.24	4.19	5.00	4.07	4.08	4.23

⑨-b 数値評価の平均
(40~50代, 性別)

行ラベル	平均 / 総合評価	平均 / 部屋	平均 / 接客・サービス	平均 / ロケーション	平均 / 朝食	平均 / 夕食	平均 / 温泉・お風呂	平均 / 設備	平均 / 清潔さ
☐A_レジャー	4.31	4.19	4.35	4.24	4.35	4.42	4.31	4.09	4.23
女性	4.34	4.26	4.41	4.26	4.38	4.45	4.36	4.19	4.27
男性	4.28	4.12	4.30	4.23	4.32	4.38	4.26	4.00	4.19
☐B_ビジネス	4.19	4.14	4.16	4.19	4.20	4.36	3.93	3.98	4.15
女性	4.22	4.22	4.27	4.22	4.39	4.50	3.97	4.10	4.21
男性	4.16	4.08	4.08	4.18	4.07	4.27	3.91	3.90	4.11

⑨-c 数値評価の平均
(60~80代, 性別)

行ラベル	平均 / 総合評価	平均 / 部屋	平均 / 接客・サービス	平均 / ロケーション	平均 / 朝食	平均 / 夕食	平均 / 温泉・お風呂	平均 / 設備	平均 / 清潔さ
☐A_レジャー	4.30	4.09	4.19	4.14	4.27	4.33	4.24	3.95	4.18
女性	4.34	4.16	4.26	4.12	4.35	4.41	4.32	4.05	4.26
男性	4.28	4.06	4.15	4.14	4.22	4.29	4.20	3.90	4.14
☐B_ビジネス	4.19	4.06	4.07	4.15	4.07	4.50	3.89	3.88	4.18
女性	4.23	4.25	4.27	4.07	4.25	4.33	4.10	4.05	4.35
男性	4.18	3.99	3.99	4.17	4.00	4.56	3.81	3.82	4.10

データ理解 — 集計結果の整理

観点	データの特徴	テキスト分析時に注意すべき点
年代別・性別	- 約30%が年代や性別を表明していない	- レビュー観点がある年代や性別に偏っている可能性
目的別	- レジャーは家族が多い、ビジネスは一人が多い	- レビューの観点が性別によって偏っている可能性
数値評価 (総合)	- 旅行目的によらず評価は高め	- コメントが好評価に偏っている可能性
数値評価 (項目ごと)	- レジャーの評価は、食事や風呂 > 設備や部屋	- 旅行目的によって評価の観点や重みが異なっている可能性
全体		

- 個人ワーク (~19:50 ※休憩込み)
 - データ集計によって発見した、**データセットに関する特徴や傾向、テキスト分析時に注意すべき点**について、検討する
 - 前ページの表を参考に、**集計結果から得られた知見を整理**する

数値評価で違いを見るのは難しい

⑧-a 数値評価の平均 (エリア別x数値評価別)

行ラベル	平均 / 総合評	平均 / 部屋	平均 / 接客・サ	平均 / ロケーシ	平均 / 朝食	平均 / 夕食	平均 / 温泉・お	平均 / 設備	平均 / 清潔さ
■A_レジャー	4.32	4.19	4.31	4.26	4.36	4.41	4.32	4.10	4.25
01_登別	4.20	4.00	4.18	4.21	4.18	4.22	4.31	3.96	4.05
02_草津	4.30	4.18	4.34	4.27	4.34	4.36	4.35	4.08	4.29
03_箱根	4.33	4.23	4.27	4.18	4.35	4.39	4.29	4.09	4.20
04_道後	4.25	4.11	4.23	4.24	4.33	4.49	4.16	4.03	4.21
05_湯布院	4.52	4.46	4.56	4.5	4.5	4.5	4.5	4.34	4.49
■B_ビジネス	4.19	4.11	4.13	4.2	4.16	4.27	3.77	3.97	4.18
06_札幌	4.25	4.19	4.17	4.2	4.2	4.2	4.2	4.02	4.27
07_名古屋	4.16	4.10	4.14	4.18	4.11	3.70	3.89	3.96	4.15
08_東京	4.17	4.10	4.12	4.26	4.09	5.00	3.84	3.95	4.09
09_大阪	4.25	4.18	4.15	4.32	4.25	4.29	3.99	4.02	4.29
10_福岡	4.12	4.00	4.09	4.16	4.18	4.67	3.77	3.89	4.15

・ユーザーのほとんどが 4～5 の評価、1～2をつけない → 本音が見えない

・ほとんどが同じ点数でもテキストを見れば差異があるかも

・すべての項目に回答する → どこに注目しているかわからない

⑧-b 数値評価の平均 (カテゴリ別x数値評価別)

行ラベル	平均 / 総合評	平均 / 部屋	平均 / 接客・サ	平均 / ロケーシ	平均 / 朝食	平均 / 夕食	平均 / 温泉・お	平均 / 設備	平均 / 清潔さ
A_レジャー	4.32	4.19	4.31	4.26	4.36	4.41	4.32	4.10	4.25
B_ビジネス	4.19	4.11	4.13	4.24	4.16	4.53	3.88	3.97	4.18

辻井康一 and 津田和彦「**テキストマイニングを用いた宿泊レビューからの注目情報抽出方法**」, デジタルプラクティス 3.4 (2012): 289-296.

【再掲】⑧-b 数値評価の平均 (カテゴリ別×数値評価別)

行ラベル	平均 / 総合評	平均 / 部屋	平均 / 接客・サ	平均 / ロケーシ	平均 / 朝食	平均 / 夕食	平均 / 温泉・お	平均 / 設備	平均 / 清潔さ
A_レジャー	4.32	4.19	4.31	4.26	4.36	4.41	4.32	4.10	4.25
B_ビジネス	4.19	4.11	4.13	4.24	4.16	4.53	3.88	3.97	4.18

● 数値評価のみから違いを見つけるのは難しい！！

- ・ ユーザーの 8割が 4～5 の評価, 1～2をつけない
- ・ ユーザーは 注目の有無に関係なくすべての項目に回答

→ **レジャーとビジネスでは、評価すべき項目も異なること**を確認した

→ **テキストと対応付ければ、同じ点数でも差異があること**を確認した


テキスト解析 (1)

(再掲) テキストマイニングの手順

- データを理解する
 - データ件数や構成比を集計 → 対象データに詳しくなる
 - 投稿者の属性(年齢、性別)の分布は?
 - 旅行目的や同伴者別の分布は?
 - 目的別やエリア別の数値評価の傾向は? (→数値評価は結果系)
- テーマを設定する
 - 解決すべき課題を決める → 分析目的を明確にする
 - 数値評価が低い原因は?
 - 高評価の施設に学ぶ改善点は?
- テキスト分析に取り組む
 - これら課題を解決するために、テキスト分析を実施 (→テキストは原因系)

テキスト分析の手順

①自然言語処理によりテキストを数値化する → ②統計解析や可視化を行う → ③結果を読み解きながら解析のための辞書を編纂する → 分析のサイクルを回していく(①へ)




- 速度重視では MeCab、精度と出力情報の豊富さ重視では JUMAN++ が有名

出典: <https://taku910.github.io/mecab/> をもとに加筆修正

形態素解析器	ChaSen	MeCab	JUMAN	JUMAN++
	コスト推定	HMM	CRF	人手
	探索方法	接続コスト最小法 (ビタビアルゴリズム)		
係り受け解析		Cabocha	CaboCha	KNP

JUMAN++ 深層学習を使った手法で、自然な言葉の繋がりを考慮した



学習・評価データ
京都大学テキストコーパス (NEWS),
京都大学ウェブ文書リードコーパス (WEB)

RNN言語モデルの学習
Webコーパス 1000万文

出所:
https://drive.google.com/file/d/1DVnrsWw4skRgC8jU6_RkeofOQEHFwctc/view?usp=sharing

- Megagon Labs と国立国語研究所の共同研究結果として公開された OSS の日本語自然言語処理ライブラリ
 - 「著作権表示」と「MIT ライセンスの全文」を記載する、という2条件のみで商用利用が可能
- **spaCy** (機械学習を組み込んだ自然言語処理ライブラリ) 上で動作するので、**係り受け解析**や**固有表現抽出**などの機能も利用可能
 - 形態素解析には **Sudachi** (徳島人工知能NLP研究所)を利用、辞書は半年に約1回の頻度で更新されている (らしい)
 - 20億文以上のWebテキストで事前学習した **Transformers** モデルも利用可能

ただし、**高い利便性や機能**の一方で**処理が遅い** (形態素解析でMeCabの10倍ぐらい)

次回の演習環境 → 注: Googleのアカウントが必要です


● 機械学習の教育・研究を目的とした研究用ツール



<https://colab.research.google.com>



<https://studiolab.sagemaker.aws/>



演習で使用



	Clab(無償版)	Studio Lab
GPU	T4(16GB)	T4(16GB)
最長実行時間	12時間	CPU:12時間 GPU:4時間
メモリ	12GB	15GB
ディスク	CPU:100GB GPU:78GB	15GB (永続化)
ターミナル	△(限定的)	○
ランタイムの保存と再開	×	○
費用	無償	無償
その他	Googleアカウントが必要	AWSアカウントは不要 (クレカ不要)

- URL: <https://github.com/haradatm/lecture-gssm2026>

haradatm/lecture-gssm2026

github.com/haradatm/lecture-gssm2026

README MIT license

lecture-gssm2026

This repository will be used for courses 01KA438 and 0ADM126 offered in 2026.

Tutorial notebooks

Notebook	Description	Colab Link
day 2.ipynb	Text Analysis (1)	Open in Colab
day 3-1.ipynb	Text Analysis (2)	Open in Colab
day 3-2.ipynb	Text Mining (1)	Open in Colab
day 4.ipynb	Text Mining (2)	Open in Colab

Project Structure

```
├── README.md
```

describe this project

Releases

No releases published
[Create a new release](#)

Packages

No packages published
[Publish your first package](#)

Contributors 1

haradatm Tomohiko HARADA

Jupyter Notebook 94.9%
Python 4.8% Shell 0.3%

Suggested workflows
Based on your tech stack

Python application [Configure](#)

「day-2.ipynb」の右隣にある「Open in Colab」をクリックして開く

● 準備

0.1 必要なパッケージのインストール

0.2 MeCab インストール (時間目安: 約3分)

0.3 CaboCha インストール (時間目安: 約4分)

0.4 セッションの再起動

0.5 動作確認


● テキスト解析 (1)

1.1 形態素解析

1.2 係り受け解析

1.3 辞書追加

目次を開く



● 形態素解析を行う (コマンドライン実行と同じ形式)

3.1 MeCab を使う

(1) そのまま出力してみる

①

```
import MeCab

tagger = MeCab.Tagger("-r ./tools/usr/local/etc/mecabrc")
print(tagger.parse("今日はいい天気です"))
```

今日	名詞, 副詞可能, *, *, *, *, 今日, キョウ, キョー
は	助詞, 係助詞, *, *, *, *, は, ハ, ワ
いい	形容詞, 自立, *, *, 形容詞・イイ, 基本形, いい, イイ, イイ
天気	名詞, 一般, *, *, *, *, 天気, テンキ, テンキ
です	助動詞, *, *, *, 特殊・デス, 基本形, です, デス, デス
EOS	

① セルをクリックして選択し、再生ボタンを押す

- この方法では、コマンドライン実行した場合と同じ形式で出力されます
- ただし、テキスト解析では、**テキストを数値化し、統計処理を行う**必要があります
- そこで、**統計処理で扱いやすい DataFrame 型**(テーブル形式)に格納します →次ページ

● 形態素解析を行う (DataFrame 型に格納する)

```
② import pandas as pd

node = tagger.parseToNode("今日はいい天気です")
features = []
while node:
    features.append(node.feature.split(','))
    node = node.next

columns = [
    "品詞", "品詞細分類1", "品詞細分類2", "品詞細分類3", "活用型", "活用形", "基本形",
    "読み", "発音",
]

pd.DataFrame(features, columns=columns)
```

[2]:

	品詞	品詞細分類1	品詞細分類2	品詞細分類3	活用型	活用形	基本形	読み	発音
0	BOS/EOS	*	*	*	*	*	*	*	*
1	名詞	副詞可能	*	*	*	*	今日	キョウ	キョー
2	助詞	係助詞	*	*	*	*	は	ハ	ワ
3	形容詞	自立	*	*	形容詞・イイ	基本形	いい	イイ	イイ
4	名詞	一般	*	*	*	*	天気	テンキ	テンキ
5	助動詞	*	*	*	特殊・デス	基本形	です	デス	デス
6	BOS/EOS	*	*	*	*	*	*	*	*

② セルをクリックして選択し、再生ボタンを押す

- この方法では、形態素解析器の出力を統計処理で扱いやすい DataFrame 型 (テーブル形式) に格納しています

練習: 入力文「今日はいい天気です」の内容を変更して、形態素解析(②)を行った結果を確認してください

● 係り受け解析を行う (コマンドライン実行と同じ形式)

4.1 CaboCha を使う

(1) そのまま出力してみる

①

```
import CaboCha

cp = CaboCha.Parser("-r ./tools/usr/local/etc/cabocharc")
tree = cp.parse("今日はいい天気です")
print(tree.toString(CaboCha.FORMAT_LATTICE))
```

```
* 0 2D 0/1 -1.041733
今日      名詞, 副詞可能, *, *, *, *, 今日, キョウ, キョー
は        助詞, 係助詞, *, *, *, *, は, ハ, ワ
* 1 2D 0/0 -1.041733
いい      形容詞, 自立, *, *, 形容詞・イイ, 基本形, いい, イイ, イイ
* 2 -1D 0/1 0.000000
天気      名詞, 一般, *, *, *, *, 天気, テンキ, テンキ
です      助動詞, *, *, *, 特殊・デス, 基本形, です, デス, デス
EOS
```

① セルをクリックして選択し、再生ボタンを押す

- この方法では、コマンドライン実行した場合と同じ形式で出力されます
- ただし、**係り元**や**係り先**の関係を把握するには、この出力形式でも、表形式でも直感的ではありません
- そこで、**係り受け関係を確認し易いツリー形式**で出力します →次ページ

● 係り受け解析を行う (係り受けペアを抽出する)

②

```
# 構文木(tree)からチャンクを取り出す
def get_chunks(tree):
    chunks = {}
    key = 0
    for i in range(tree.size()):
        tok = tree.token(i)
        if tok.chunk:
            chunks[key] = tok.chunk
            key += 1
    return chunks

# チャンク(chunk)から表層形を取り出す
def get_surface(chunk):
    surface = ''
    begin = chunk.begin
    end = chunk.end
    for i in range(begin, end):
        surface += tree.token(i).text
    return surface
```

← 繰り返し呼ばれる処理などをまとめて関数として定義したもの

③

```
tree = cp.parse("今日はいい天気です")
chunks = get_chunks(tree)

for from_chunk in chunks.values():
    if from_chunk.link < 0:
        continue
    to_chunk = chunks[from_chunk.link]

    from_surface = get_surface(from_chunk)
    to_surface = get_surface(to_chunk)

    print(from_surface, '->', to_surface)
```

今日は -> 天気です
いい -> 天気です

② セルをクリックして選択し、再生ボタンを押す (③より前に一度実行しておく)

③ セルをクリックして選択し、再生ボタンを押す

• この方法では、係り受け解析器の出力を**係り元と係り先の関係**を持つ単語のペアを抽出しています

練習: 入力文「**今日はいい天気です**」の内容を変更して、係り受け解析(③のみ)を行った結果を確認してください

レポート課題

- 以下を PDF ファイルで提出 してください
 - データ集計により作成した「集計表」のキャプチャ (P.90~94) ※ページ番号は各スライド右下に記載
 - 作成した「集計結果の整理」の表 (P.95) ※ページ番号は各スライド右下に記載
- ※ 何らかの事情で上記2つを提出できない場合、本日の講義の感想を文章で記述してください

レポート形式	提出先	期限
PDF	manaba	次回～18:20