

人文社会ビジネス科学学術院 ビジネス科学研究群 2026年度 春C

テキストマイニングの実践 day 3

- URL: <https://github.com/haradatm/lecture-gssm2026>

注: 講義資料は、講義開始前まで更新する可能性があります。常に最新のスライドを確認するようにしてください。

①「**slides**」をクリックして開く

②「**day-N.pdf**」をクリックして開く

③ダウンロードボタン「↓」をクリック

人文社会ビジネス科学学術院 ビジネス科学研究群 2025年度 春C
テキストマイニングの実践

スケジュール

day 1

- 講義(後半) — 自然言語処理とLLM

day 2

- 講義 — テキストマイニングの手順
- 講義&演習 — データ理解
- 講義&演習 — テキスト解析 (1)

day 3

- 講義&演習 — テキスト解析 (2)
- 講義&演習 — テキスト分析 (1)

day 4

- 講義&演習 — テキスト分析 (2)

day 5

- 演習 — テキスト分析 (発表会)
- 講義&演習 — LLMを用いたテキスト分析
- ラップアップ — Q&A

(前回) day 2 – レポート課題

- 以下を PDF ファイルで提出 してください
 - データ集計により作成した「集計表」のキャプチャ (P.90~94) ※ページ番号は各スライド右下に記載
 - 作成した「集計結果の整理」の表 (P.95) ※ページ番号は各スライド右下に記載
- ※ 何らかの事情で上記2つを提出できない場合、本日の講義の感想を文章で記述してください

レポート形式	提出先	期限
PDF	manaba	次回～18:20

(参考) データ理解 ― 集計結果の整理

観点	データの特徴	テキスト分析時に注意すべき点
年代別・性別	- 約30%が年代や性別を表明していない - 年代別では、目的によらず40～60代が多い - 男性の投稿がやや多いが、女性も一定比率存在 - レジャーは男女差が比較的小さく、ビジネスは男性が多い	- レビュー観点がある年代や性別に偏っている可能性 → 偏りあるなら乱暴に一般化せず丁寧にみていく方がよい - 無回答の30%は分布が異なる可能性 → 無回答が多いなら属性に引っ張られない解釈がよい
目的別	- レジャーは家族が多い、ビジネスは一人が多い（出張は単独で宿泊するケースが多い） - ビジネスは出張中心だが、家族や観光も混在している - レジャーの中でも、道後は男性の一人客が多い（道後はもはや仕事で行く場所か）	- 同行者により評価観点が大きく変わる可能性（家族→体験、個人→機能） - レビューの観点がカテゴリと一致していない可能性（道後→仕事） - ビジネスでもレジャー要素が混在する可能性
数値評価 (項目ごと)	- 旅行目的によらず評価は高め - レジャーがビジネスより評価が高め - レジャーは「食事・接客・温泉」が高評価 - ビジネスは「温泉・設備」が低評価 - ロケーション・部屋はカテゴリ差が小さい（差別化しにくい）	- 好評価しか投稿しない → コメントが好評価に偏る可能性 - 旅行目的によって投稿の動機が異なっている可能性 - 評価を押し上げるのは体験要素 → 接客・食事・温泉 - 評価を下げるのは機能・ストレス要素 → 設備・清潔 - ビジネスの夕食評価は欠損が多く偏りあり（解釈注意）
数値評価 (エリアごと)	- レジャーの中で高評価が多いのは湯布院、登別が少ない - ビジネスの中で高評価が多いのは札幌・大阪、名古屋・福岡がやや少ない	エリアごとに利用目的・評価する項目が異なる可能性（道後→一人利用多く温泉より食事・接客が強み、大阪→観光が混在）
その他	- 本データは「楽天トラベルにレビュー投稿する層」の特性であり、一般旅行者全体の傾向とは乖離する可能性あり - 分析結果は「誰が書いているか」という構成バイアスを前提に解釈する必要あり	


テキスト解析 (2)

(再掲) テキストマイニングの手順

- データを理解する
 - データ件数や構成比を集計 → 対象データに詳しくなる
 - 投稿者の属性(年齢、性別)の分布は?
 - 旅行目的や同伴者別の分布は?
 - 目的別やエリア別の数値評価の傾向は? (→数値評価は結果系)
- テーマを設定する
 - 解決すべき課題を決める → 分析目的を明確にする
 - 数値評価が低い原因は?
 - 高評価の施設に学ぶ改善点は?
- テキスト分析に取り組む
 - これら課題を解決するために、テキスト分析を実施 (→テキストは原因系)

テキスト分析の手順

①自然言語処理によりテキストを数値化する → ②統計解析や可視化を行う → ③結果を読み解きながら解析のための辞書を編纂する → 分析のサイクルを回していく(①へ)



● 社会調査データを分析する目的で開発されたフリー(無料)のツール

- 高機能かつ商用可能でフリー
- Rを用いた多変量解析と可視化
- 実装されている分析手法

- ・ 階層的クラスタ分析
- ・ 多次元尺度構成法(MDS)
- ・ 対応分析
- ・ 共起ネットワーク
- ・ 自己組織化マップ
- ・ 文書のクラスタ分析
- ・ トピックモデル (LDA)

論文検索サービスも提供 → <http://khcoder.net/bib.html>

研究事例リスト

KH Coderを用いたご研究の成果を発表された際には、書誌情報をフォームにご記入いただけますと幸いです。

出版年: すべて -2010 11 12 13 14 15 16 17 18 19 20 21 22 2023-

著者名: すべて あ か さ た な は ま や ら わ A-Z

キーワード:

ヒット件数: 0200 / 6135

KH Coderを用いた研究事例のリスト ◀ 6135件

※2023/6/16 現在

→1646→2042→2695→3741件→4554件→昨年5355件→6135件)


	Starting	Base	Master	Pro
通常ライセンス 販売価格(税込) ※下段は、バージョンアップに追従できるアップデートのサブスクリプション費用 (1年間)	無料	59,950 (43,780)	196,900 (43,780)	396,000 (43,780)
アカデミック・ライセンス 販売価格(税込) ※下段は、バージョンアップに追従できるアップデートのサブスクリプション費用 (1年間)	無料	24,750 (18,480)	69,850 (18,480)	—
インストール可能台数 ※ライセンス保有者が管理するPCに限る	1台	2台	2台	2台

	Starting	Base	Master	Pro
無料で分析を始められる 一部機能制限ありの公開テスト(beta)版 ・ 分析対象はデータファイルの最初の100件目まで ・ 強制抽出語と無視する語の指定はそれぞれ1語のみ ・ 分析対象の品詞タイプを選択できない	○	—	—	—
機能制限なしの正式版 外部プラグイン「文錦@シリーズ」購入による機能追加も可能	—	○	○	○
アップデートのサブスクリプション (1年間有効) KH Coderのバージョンアップに追従できる便利なバッチを提供	—	○	○	○
インストール／セットアップのサポート KH Coderの導入段階のトラブルシューティング	—	—	○	○
セミナー受講券 (1年半以内有効) 「計量テキスト分析公式セミナー」初級編・ステップアップ編に各1回参加可	—	—	1名	1名
使い方のQ&A対応 使い方に関する困り事やご質問にメールでサポート	—	—	—	6回/年

出典: <https://www.screen.co.jp/as/solution/khcoder>

共起ネットワーク

抽出語またはコードを用いて、出現パターンの似通ったものを線で結んだ図、すなわち共起関係を線（edge）で表したネットワークを描く機能です。



共起の程度が非常に強いものだけを線で結んだ図




やや弱い共起関係も描画に含め、自動的にグループ分け（色分け）




出現数が多い語ほど大きく、また共起の程度が強いほど太い線で描画

多次元尺度構成法（MDS）


同じく抽出語またはコードを用いての、多次元尺度構成法です。



2次元の解




New! クラスタリングと色分け




3次元の解

対応分析


同じく抽出語またはコードを用いての、対応分析です。



同時布置図



New! バブルプロット




複数の外部変数を用いた多重対応分析

分析手法	説明
共起ネットワーク	- 同時に出現した単語同士をネットワークで結んで図示したもの - 同時に出現したかといった共起の有無を集計し、ネットワークを作成 - 関係の強さ Jaccard 係数で評価し、媒介性やグラフクラスタリングを使ってサブグラフも検出できる
多次元尺度構成法（MDS）	- 出現パターンの似た単語同士を近くに置くよう図示したもの - 出現パターンとは、ある単語がどの文書に出現したかといった関係を単語ベクトルとして表現したもの - 似ている(=距離が近い)の計算は Jaccard、ユークリッド、コサイン距離のいずれかで求める
対応分析 (コレスポンデンス分析)	- 出現パターンの似た単語や外部変数を近くに置くよう図示したもの - 単語と単語または外部変数が同時に出現した頻度をクロス集計し、相関が最大になるような2軸でプロット - PCA が元の情報をそのまま可視化するのに対して、対応分析は<u>似ているものを近くに表示する</u> - 外部変数も同時にプロットできる


トピックモデル (LDA)

文書ごとにトピックの出現割合を表示したり、各トピックに高い確率で出現する語を表示できます。




階層的クラスター分析

抽出語の階層的クラスター分析を行い、デンドログラムを表示します。抽出語だけでなくコーディング結果（コード）についても、同じように分析を行えます。



文書のクラスター分析


文書の分類を行うクラスター分析です。



分析手法	説明
トピックモデル (LDA)	- 文書が複数のトピックを持つと仮定、文書ごとにトピックの出現割合、各トピックに高確率で出現する語を表示 - R の topicmodels パッケージに含まれる LDA 関数(ギブスサンプリング)を利用 (乱数のシードは固定) - トピックモデルは教師なし学習のため、コーディングルールで単語を集約するよりも客観性が高い
階層的クラスター分析	- 出現パターンの似た単語同士をグルーピング(クラスタリング)して、樹形図にしたもの - 出現パターンは、ある単語がどの文書に出現したかといった関係を単語ベクトルとして表現したもの - 似ている(=距離が近い)の計算は Jaccard、ユークリッド、コサイン距離のいずれかで求める
文書のクラスター分析	- 似た文書同士をグルーピング(クラスタリング)して、樹形図にしたもの - 各文書は、文書中に出現する単語の有無でベクトル化した文書ベクトルで表現 - 似ている(=距離が近い)の計算は Jaccard、ユークリッド、コサイン距離のいずれかで求める - いわゆる Ward法, 群平均法, 最遠隣法で階層クラスタを作成する

● プロジェクトの作成


①メニューから「プロジェクト」「新規」を選択 (注1)



注1: 次回 KH Coderを起動した時は「新規」ではなく「開く」を選択します

注2: ②のファイル選択後、ここに「テキスト」等の選択項目が表示されるまで数分がかかります

②「参照」をクリックして「rakuten-1000-2022-2023.xlsx」を開く



③「コメント」を選択 (注2)

④「MeCab」を選択

⑤説明「楽天トラベル」等を入力

⑥「OK」をクリック

● 前処理(形態素解析)の実行

①メニューから「前処理」「語の取捨選択」を選ぶ

注1: EXCELファイルを読み込んで分析する場合、あらかじめ「---cell---」が入力されています

注2: メニューから「前処理」「複合語の検出」を選ぶと、**複合語候補の一覧を出力**できます

②複合語など強制的に抽出したい語あればここに登録する (例: **湯畑**)

③削除語(ストップワード)など抽出したくない語あればここに登録する

④メニューから「前処理」「前処理の実行」を選ぶ


《文錦》テキスト・変数の編集 ※
テキストのチェック
前処理の実行
語の取捨選択
複合語の検出
《文錦》表記ゆれ & 同義語 ※
語の抽出結果を確認

処理が完了しました。
経過時間: 00:01:55
OK

● 共起ネットワークの作成(1)


①メニューから「ツール」「抽出語」「共起ネットワーク」を選ぶ

②「集計単位」として「H5」を選んで「OK」をクリック



③品詞を選択する,例えば
名詞, 名詞B, 名詞C, 未知語,
形容詞, 形容詞B, 形容動詞, タグ


⑤「カラー」の箇所を「サブグ
ラフ検出(modularity)」に変更



④「調整」をクリックして「強い共起
関係ほど…」をチェック

● 外部変数を利用する

①メニューから「ツール」「外部変数と見出し」を開く



④「特徴語」「一覧(Excel形式)」を選択


	A	B	C	D	E	F	G	H	I	J	K
1											
2		01_登別		02_草津		03_箱根		04_道後			
3	風呂	.115	湯畑	.327	美味しい	.136	温泉	.109			
4	温泉	.107	温泉	.136	露天風呂	.134	立地	.082			
5	美味しい	.094	風呂	.126	風呂	.116	最高	.066			
6	良い	.093	宿	.120	部屋	.109	広い	.063			
7	バイキング	.090	美味しい	.102	良い	.106	浴場	.059			
8	残念	.078	良い	.100	温泉	.102	よい	.058			
9	ない	.077	部屋	.096	宿	.097	フロント	.057			
10	夕食	.076	最高	.090	スタッフ	.096	大変	.057			
11	種類	.075	夕食	.085	夕食	.095	夕食	.055			
12	露天風呂	.074	ない	.074	ない	.083	便利	.055			
13		05_湯布院		06_札幌		07_名古屋		08_東京			
14	宿	.180	ホテル	.092	ホテル	.086	駅	.102			
15	美味しい	.144	立地	.077	便利	.072	ホテル	.086			
16	露天風呂	.135	便利	.077	駅	.070	便利	.078			
17	風呂	.127	綺麗	.071	綺麗	.069	立地	.077			
18	温泉	.124	浴場	.070	フロント	.066	近い	.071			
19	最高	.114	フロント	.065	立地	.065	綺麗	.064			
20	スタッフ	.110	広い	.063	近い	.059	快適	.063			
21	家族	.104	快適	.056	アメニティ	.056	コンビニ	.059			
22	部屋	.099	駅	.056	快適	.055	フロント	.055			
23	良い	.097	ベッド	.055	コンビニ	.051	アメニティ	.052			
24		09_大阪		10_福岡							
25	ホテル	.108	ホテル	.090							
26	駅	.096	便利	.087							
27	便利	.080	立地	.082							
28	立地	.074	駅	.0							
29	綺麗	.072	フロント								
30	フロント	.067	綺麗								
31	快適	.064	トイレ								
32	広い	.064	コンビニ								
33	近い	.064	よい								
34	アメニティ	.054	快適								

各エリアの特徴語を10件ずつ
一覧 (数値は Jaccard係数)

● 共起ネットワークの作成(3)


①メニューから「ツール」「抽出語」「共起ネットワーク」を選ぶ

②「集計単位」として「H5」を選んで「OK」をクリック



④「語-外部変数・見出し」を選択し、「カテゴリ」を選ぶ


③品詞を選択する,例えば
名詞, 名詞B, 名詞C, 未知語,
形容詞, 形容詞B, 形容動詞, タグ



⑤「調整」をクリックして「強い共起関係ほど…」をチェック

● 対応分析による探索(1)


①メニューから「ツール」「抽出語」「対応分析」を選ぶ



②「H5」になっていることを確認

③「抽出語×外部変数」「カテゴリ」「エリア」を選択

④「OK」をクリック



● コーディングルール (語ではなくコンセプトを数える方法)

①メニューから「ツール」「文書」「文書検索」を選ぶ

②「参照」をクリックして
「coding-rule.txt」を開く

③ダブルクリック

④「H5」を選択

ダブルクリックで、さらに
広い範囲の文脈を表示可能

coding-rule.txt の中身

*ポジ

良い or 美味しい or 広い or 多い or 素晴らしい or 嬉しい or 気持ちよい or 楽しい or 近い or 大きい or 気持ち良い or 温かい or 早い or 優しい or 新しい or 暖かい or 快い or 明るい or 美しい or 可愛い

*ネガ

古い or 無い or 高い or 悪い or 小さい or 狭い or 少ない or 寒い or 遅い or 熱い or 欲しい or 暑い or 冷たい or 遠い or 臭い or 暗い

*風呂1-2

<>風呂-->1 | <>風呂-->2


*風呂4-5

<>風呂-->4 | <>風呂-->5

外部変数

● 対応分析による探索(3)

①メニューから「ツール」「コーディング」「対応分析」を選ぶ




②「文」になっていることを確認

③見たい「コード」を選択

④「抽出語×外部変数」「カテゴリ」「エリア」を選択

⑤「OK」をクリック



● トピックモデルによる分析

① メニューから「ツール」「文書」「トピックモデル」「トピックの推定」を選ぶ

② 「H5」になっていることを確認

③ 「トピック数」を指定 (例:6)

④ 「OK」をクリック

⑤ 「マップ」をクリック

⑥ 「エリア」を選択


レジャーとビジネスで注目している観点(=トピック)が異なる

The screenshot displays the KH Coder software interface for Topic Model (LDA) analysis. The 'Topic Estimation' window is open, showing the 'Collection Unit and Word Extraction' tab. The 'Collection Unit' is set to 'H5', and the 'Number of Topics' is set to 6. The 'Minimum Occurrence' is 49, and the 'Minimum Document Count' is 1. The 'Word Selection by Part of Speech' tab is active, with 'Nouns' and 'Adjectives' selected. The 'Current number of words used with the current settings' is 46. The 'OK' button is highlighted. The 'Topic Estimation Results' window is also open, showing the 'Info' tab with 'Collection Unit: h5', 'Number of Topics: 6', and 'Distinct Words: 46'. The 'Topics' tab shows a table of topic proportions for 6 topics across various words. The 'Map' button is highlighted. The 'Topic Ratio Map' window is open, showing a heatmap of topic ratios for 10 documents. The 'Area' button is highlighted. A blue dashed box highlights the 'Map' window, with a note indicating that the perspective (topic) is different for 'Leisure' and 'Business'.

Topic	部屋	美味しい	ホテル	風呂	ない	良い
#1	0.534	0.216	0.315	0.305	0.235	0.235
#2	0.136	0.185	0.128	0.093	0.128	0.128
#3	0.122	0.126	0.109	0.084	0.123	0.123
#4	0.079	0.112	0.101	0.075	0.105	0.105
#5	0.055	0.101	0.091	0.073	0.102	0.102
#6	0.033	0.084	0.083	0.066	0.085	0.085

共起ネットワーク

抽出語またはコードを用いて、出現パターンの似通ったものを線で結んだ図、すなわち共起関係を線（edge）で表したネットワークを描く機能です。



共起の程度が非常に強いものだけを線で結んだ図




やや弱い共起関係も描画に含め、自動的にグループ分け（色分け）




出現数が多い語ほど大きく、また共起の程度が強いほど太い線で描画

多次元尺度構成法（MDS）


同じく抽出語またはコードを用いての、多次元尺度構成法です。



2次元の解



New! クラスタリングと色分け




3次元の解

対応分析

同じく抽出語またはコードを用いての、対応分析です。

Google Colab Notebook (無償) で再実装し,講義で利用



同時布置図


New! バブルプロット

複数の外部変数を用いた多重対応分析

分析手法	説明
共起ネットワーク	- 同時に出現した単語同士をネットワークで結んで図示したもの - 同時に出現したかといった共起の有無を集計し、ネットワークを作成 - 関係の強さ Jaccard 係数で評価し、媒介性やグラフクラスタリングを使ってサブグラフも検出できる
多次元尺度構成法（MDS）	- 出現パターンの似た単語同士を近くに置くよう図示したもの - 出現パターンとは、ある単語がどの文書に出現したかといった関係を単語ベクトルとして表現したもの - 似ている(=距離が近い)の計算は Jaccard、ユークリッド、コサイン距離のいずれかで求める
対応分析 (コレスポンデンス分析)	- 出現パターンの似た単語や外部変数を近くに置くよう図示したもの - 単語と単語または外部変数が同時に出現した頻度をクロス集計し、相関が最大になるような2軸でプロット - PCA が元の情報をそのまま可視化するのに対して、対応分析は似ているものを近くに表示する - 外部変数も同時にプロットできる


トピックモデル (LDA)

文書ごとにトピックの出現割合を表示したり、各トピックに高い確率で出現する語を表示できます。




階層的クラスター分析

抽出語の階層的クラスター分析を行い、デンドログラムを表示します。抽出語だけでなくコーディング結果（コード）についても、同じように分析を行えます。



文書のクラスター分析

文書の分類を行うクラスター分析です。



分析手法	説明
トピックモデル (LDA)	- 文書が複数のトピックを持つと仮定、文書ごとにトピックの出現割合、各トピックに高確率で出現する語を表示 - R の topicmodels パッケージに含まれる LDA 関数(ギブスサンプリング)を利用 (乱数のシードは固定) - トピックモデルは教師なし学習のため、コーディングルールで単語を集約するよりも客観性が高い
階層的クラスター分析	- 出現パターンの似た単語同士をグルーピング(クラスタリング)して、樹形図にしたもの - 出現パターンは、ある単語がどの文書に出現したかといった関係を単語ベクトルとして表現したもの - 似ている(=距離が近い)の計算は Jaccard、ユークリッド、コサイン距離のいずれかで求める
文書のクラスター分析	- 似た文書同士をグルーピング(クラスタリング)して、樹形図にしたもの - 各文書は、文書中に出現する単語の有無でベクトル化した文書ベクトルで表現 - 似ている(=距離が近い)の計算は Jaccard、ユークリッド、コサイン距離のいずれかで求める - いわゆる Ward法, 群平均法, 最遠隣法で階層クラスタを作成する

KH Coder の解析・分析手法

- KH Coder は「単語と単語」、「外部変数と単語」の**関係に注目した分析**が得意
 - 特徴的な単語を見つける
 - ・ 特定の文書に特徴的な単語を見つける → TF・IDF
→ その文書に特に頻出するが、他の文書ではそれほどではない
 - **特徴的な関係を見つける**
 - ・ 関係性の強い単語と単語を見つける → **共起ネットワーク(Jaccard係数)**
例) 単語:「風呂」と 単語:「広い」に関係が強そう
 - ・ 関係性の強い単語と外部変数を見つける → **対応分析(カイ2乗値)**
例) 外部変数:「レジャー」と 単語:「風呂」は関係が強そう


- 「文書-抽出語」表 {
【行】ある文中に出現する単語の数を要素とする文ベクトル
【列】全文中に出現する単語の数を要素とする単語ベクトル

「文書-抽出語」one-hot ベクトル表

カテゴリー	エリア	文書ID	風呂	良い	部屋	宿	スタッ	美味し	綺麗な	広い	立地	最高	残念だ	バイク	便利だ	大変だ	夕食	価格	多い	快適だ	駅	安い	近い	気	清潔だ	感じ	子供	丁寧だ	食事	バス	嬉しい	種類	素晴ら	気持ち	家族	古い	親切な	人
A_レジャー	01_登別	1	0	0	1	0	0	0	0	0	0	0	1	0	0	0	0	0	1	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0
A_レジャー	01_登別	2	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0
A_レジャー	01_登別	3	1	1	0	0	1	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0
A_レジャー	01_登別	4	1	0	0	1	0	1	0	0	0	0	0	0	1	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0
A_レジャー	01_登別	5	1	1	1	0	1	0	1	0	0	0	1	1	0	0	0	0	1	0	0	0	0	0	0	1	0	0	0	0	0	0	1	0	0	1	0	0
A_レジャー	01_登別	6	1	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	
A_レジャー	01_登別	7	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	
A_レジャー	01_登別	8	1	1	1	0	0	0	1	1	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
A_レジャー	01_登別	9	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	
A_レジャー	01_登別	10	0	0	1	1	0	0	0	0	0	0	0	1	0	0	1	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0


「抽出語-抽出語」共起頻度表 (共起ネットワーク)

表層	風呂	良い	部屋	宿	スタッ	美味し	綺麗だ	広い	立地	最高	残念だ	バイキ	便利だ
風呂	4105	2391	2332	1492	1007	1345	790	684	474	625	554	510	321
良い	0	4844	2598	1726	1351	1335	909	720	809	435	587	492	421
部屋	0	0	4707	1618	1280	1288	1236	991	656	508	643	460	499
宿	0	0	0	2956	912	869	564	441	460	336	338	316	325
スタッフ	0	0	0	0	2175	663	435	309	312	214	292	231	205
美味しい	0	0	0	0	0	2448	434	369	241	318	290	479	178
綺麗だ	0	0	0	0	0	0	1610	333	229	160	187	162	172
広い	0	0	0	0	0	0	0	1213	178	138	144	156	157
立地	0	0	0	0	0	0	0	0	1177	182	129	93	243
最高	0	0	0	0	0	0	0	0	0	993	93	137	50
残念だ	0	0	0	0	0	0	0	0	0	0	990	146	66
バイキング	0	0	0	0	0	0	0	0	0	0	0	933	74



「外部変数-抽出語」クロス集計表 (対応分析)

	風呂	良い	部屋	宿	スタッ	美味し	綺麗だ	広い	立地	最高	残念だ	バイキ	便利だ
A_レジャー	2963	2625	2403	1564	1165	1786	743	625	436	701	623	639	246
B_ビジネス	1142	2219	2304	1392	1010	662	867	588	741	292	367	294	740
01_登別	609	503	435	245	183	300	133	141	33	144	170	218	26
02_草津	626	578	463	363	227	376	163	109	130	158	129	164	66
03_箱根	588	528	552	335	262	431	160	142	42	136	142	138	29
04_道後	497	498	429	290	203	247	156	109	150	81	78	105	94
05_湯布院	643	518	524	331	290	432	131	124	81	182	104	14	31
06_札幌	252	453	444	297	192	165	153	124	156	65	71	76	151
07_名古屋	251	455	450	261	209	124	202	119	127	50	67	52	131
08_東京	179	421	439	253	212	89	158	104	136	56	70	35	146
09_大阪	254	459	525	287	203	136	200	134	163	63	88	66	176
10_福岡	206	431	446	294	194	148	154	107	159	58	71	65	136




- 「文書-抽出語」表 {
【行】ある文中に出現する単語の数を要素とする文ベクトル
【列】全文中に出現する単語の数を要素とする単語ベクトル

「文書-抽出語」one-hot ベクトル表

カテゴリー	エリア	文書ID	風呂	良い	部屋	宿	スタッフ	美味しい	綺麗な	広い	立地	最高	残念だ	バイク	便利だ	大変だ	夕食	価格	多い	快適だ	駅	安い	近い	気	清潔だ	感じ	子供	丁寧だ	食事	バス	嬉しい	種類	素晴らしい	気持ち	家族	古い	親切な	人	
A_レジャー	01_登別	1	0	0	1	0	0	0	0	0	0	0	1	0	0	0	0	0	1	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	
A_レジャー	01_登別	2	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0
A_レジャー	01_登別	3	1	1	0	0	1	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0
A_レジャー	01_登別	4	1	0	0	1	0	1	0	0	0	0	0	0	1	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0
A_レジャー	01_登別	5	1	1	1	0	1	0	1	0	0	0	1	1	0	0	0	0	1	0	0	0	0	0	0	1	0	0	0	0	0	0	0	1	0	0	1	0	0
A_レジャー	01_登別	6	1	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	
A_レジャー	01_登別	7	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	
A_レジャー	01_登別	8	1	1	1	0	0	0	1	1	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
A_レジャー	01_登別	9	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	
A_レジャー	01_登別	10	0	0	1	1	0	0	0	0	0	0	0	1	0	0	1	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0


「抽出語-抽出語」共起頻度表 (共起ネットワーク)

表層	風呂	良い	部屋	宿	スタッフ	美味しい	綺麗な	広い	立地	最高	残念だ	バイク	便利だ
風呂	4105	2391	2332	1492	1007	1345	790	684	474	625	554	510	321
良い	0	4844	2598	1726	1351	1335	909	720	809	435	587	492	421
部屋	0	0	4707	1618	1280	1288	1236	991	656	508	643	460	499
宿	0	0	0	2956	912	869	564	441	460	336	338	316	325
スタッフ	0	0	0	0	2175	663	435	309	312	214	292	231	205
美味しい	0	0	0	0	0	2448	434	369	241	318	290	479	178
綺麗な	0	0	0	0	0	0	1610	333	229	160	187	162	172
広い	0	0	0	0	0	0	0	1213	178	138	144	156	157
立地	0	0	0	0	0	0	0	0	1177	182	129	93	243
最高	0	0	0	0	0	0	0	0	0	993	93	137	50
残念だ	0	0	0	0	0	0	0	0	0	0	990	146	66
バイク	0	0	0	0	0	0	0	0	0	0	0	933	74
便利だ	0	0	0	0	0	0	0	0	0	0	0	0	205




「外部変数-抽出語」クロス集計表 (対応分析)


	風呂	良い	部屋	宿	スタッフ	美味しい	綺麗な	広い	立地	最高	残念だ	バイク	便利だ
A_レジャー	2963	2625	2403	1564	1165	1786	743	625	436	701	623	639	246
B_ビジネス	1142	2219	2304	1392	1010	662	867	588	741	292	367	294	740
01_登別	609	503	435	245	183	300	133	141	33	144	170	218	26
02_草津	626	578	463	363	227	376	163	109	130	158	129	164	66
03_箱根	588	528	552	335	262	431	160	142	42	136	142	138	29
04_道後	497	498	429	290	203	247	156	109	150	81	78	105	94
05_湯布院	643	518	524	331	290	432	131	124	81	182	104	14	31
06_札幌	252	453	444	297	192	165	153	124	156	65	71	76	151
07_名古屋	251	455	450	261	209	124	202	119	127	50	67	52	131
08_東京	179	421	439	253	212	89	158	104	136	56	70	35	146
09_大阪	254	459	525	287	203	136	200	134	163	63	88	66	176
10_福岡	206	431	446	294	194	148	154	107	159	58	71	65	136




- 共起頻度の高いエッジを残す



- Jaccard 係数が上位のエッジを残す



- Jaccard係数、Dice係数、Simpson係数→ **共起の強さ** を測る
 - 1つ文書に含まれる語が少ないケース、各語が一部の文中にしか含まれていないケースに向いている →スパースなデータ分析向き
 - KHCoder では、Jaccard 係数 が標準的に用いられる




$$\text{語Aと語Bの Jaccard 係数} = \frac{c}{a+b+c}$$

- 1つの文の中に語が**1回出現した場合も10回出現した場合も単に「出現あり」**(2値)と見なしてカウントした語と語の共起数を計算
- 語Aと語Bの**どちらも出現していない文**(0-0対)が沢山あっても語Aと語Bが類似しているとは見なさない

距離尺度 - ②ベクトル間の類似度に基づく距離

- ユークリッド距離、コサイン距離 → **出現パターンが似てる** を測る
 - 1つひとつの文が長く、各文中での語の出現回数の大小が重要なケースに向いている
→ 語が1回出現したか、10回出現したかを区別したい

ユークリッド距離	コサイン距離
サイズ(出現回数の大小)の差までも見る場合向き	傾きが似ているかどうかだけを見る場合向き
$d(x,y) = \sqrt{\sum (x_i - y_i)^2}$	$d(x,y) = \frac{\sum x_i y_i}{\sqrt{\sum x_i^2 \sum y_i^2}}$



※ **x, y** はそれぞれの単語ベクトル (単語の出現パターン)


- 「文書-抽出語」表 {
【行】ある文中に出現する単語の数を要素とする文ベクトル
【列】全文中に出現する単語の数を要素とする単語ベクトル

「文書-抽出語」one-hot ベクトル表

カテゴリー	エリア	文書ID	風呂	良い	部屋	宿	スタッフ	美味し	綺麗な	広い	立地	最高	残念だ	バイク	便利だ	大変だ	夕食	価格	多い	快適だ	駅	安い	近い	気	清潔だ	感じ	子供	丁寧だ	食事	バス	嬉しい	種類	素晴らしい	気持ち	家族	古い	親切な	人	
A_レジャー	01_登別	1	0	0	1	0	0	0	0	0	0	0	1	0	0	0	0	0	1	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	
A_レジャー	01_登別	2	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0
A_レジャー	01_登別	3	1	1	0	0	1	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0
A_レジャー	01_登別	4	1	0	0	1	0	1	0	0	0	0	0	0	1	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0
A_レジャー	01_登別	5	1	1	1	0	1	0	1	0	0	0	1	1	0	0	0	0	1	0	0	0	0	0	0	1	0	0	0	0	0	0	0	1	0	0	1	0	0
A_レジャー	01_登別	6	1	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	
A_レジャー	01_登別	7	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	
A_レジャー	01_登別	8	1	1	1	0	0	0	1	1	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
A_レジャー	01_登別	9	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	
A_レジャー	01_登別	10	0	0	1	1	0	0	0	0	0	0	0	1	0	0	1	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0


「抽出語-抽出語」共起頻度表 (共起ネットワーク)

表層	風呂	良い	部屋	宿	スタッフ	美味し	綺麗だ	広い	立地	最高	残念だ	バイク	便利だ
風呂	4105	2391	2332	1492	1007	1345	790	684	474	625	554	510	321
良い	0	4844	2598	1726	1351	1335	909	720	809	435	587	492	421
部屋	0	0	4707	1618	1280	1288	1236	991	656	508	643	460	499
宿	0	0	0	2956	912	869	564	441	460	336	338	316	325
スタッフ	0	0	0	0	2175	663	435	309	312	214	292	231	205
美味しい	0	0	0	0	0	2448	434	369	241	318	290	479	178
綺麗だ	0	0	0	0	0	0	1610	333	229	160	187	162	172
広い	0	0	0	0	0	0	0	1213	178	138	144	156	157
立地	0	0	0	0	0	0	0	0	1177	182	129	93	243
最高	0	0	0	0	0	0	0	0	0	993	93	137	50
残念だ	0	0	0	0	0	0	0	0	0	0	990	146	66
バイク	0	0	0	0	0	0	0	0	0	0	0	933	74
便利だ	0	0	0	0	0	0	0	0	0	0	0	0	205



「外部変数-抽出語」クロス集計表 (対応分析)

	風呂	良い	部屋	宿	スタッフ	美味し	綺麗だ	広い	立地	最高	残念だ	バイク	便利だ
A_レジャー	2963	2625	2403	1564	1165	1786	743	625	436	701	623	639	246
B_ビジネス	1142	2219	2304	1392	1010	662	867	588	741	292	367	294	740
01_登別	609	503	435	245	183	300	133	141	33	144	170	218	26
02_草津	626	578	463	363	227	376	163	109	130	158	129	164	66
03_箱根	588	528	552	335	262	431	160	142	42	136	142	138	29
04_道後	497	498	429	290	203	247	156	109	150	81	78	105	94
05_湯布院	643	518	524	331	290	432	131	124	81	182	104	14	31
06_札幌	252	453	444	297	192	165	153	124	156	65	71	76	151
07_名古屋	251	455	450	261	209	124	202	119	127	50	67	52	131
08_東京	179	421	439	253	212	89	158	104	136	56	70	35	146
09_大阪	254	459	525	287	203	136	200	134	163	63	88	66	176
10_福岡	206	431	446	294	194	148	154	107	159	58	71	65	136



カイ2乗値

- カイ2乗値は「無関係でない」度合いを測る尺度 → カテゴリと変数間の関連性を測定

カイ2乗値 =
$$\frac{(\text{観測度数}_{ij} - \text{期待度数}_{ij})^2}{\text{期待度数}_{ij}}$$


「観測度数」: カテゴリと変数に従ってクロス集計された度数
「期待度数」: 変数が互いに独立している場合に期待される度数
「観測度数 - 期待度数」: 実際の度数と独立と期待される度数の差

- カイ2乗値も大きい → カテゴリと変数間の関係が**期待より強い**を示す


クロス集計表 (観測度数)							期待度数							観測度数-期待度数							カイ2乗値						
	風呂	良い	部屋	宿	スタッフ	合計		風呂	良い	部屋	宿	スタッフ	合計		風呂	良い	部屋	宿	スタッフ	合計		風呂	良い	部屋	宿	スタッフ	合計
01_登別	609	503	435	245	183	1975	01_登別	431.54	509.23	494.83	310.75	228.65	1975.00	01_登別	177.46	-6.23	-59.83	-65.75	-45.65	0.00	01_登別	72.97	0.08	7.23	13.91	9.11	103.31
02_草津	626	578	463	363	227	2257	02_草津	493.16	581.94	565.48	355.12	261.30	2257.00	02_草津	132.84	-3.94	-102.48	7.88	-34.30	0.00	02_草津	35.78	0.03	18.57	0.17	4.50	59.06
03_箱根	588	528	552	335	262	2265	03_箱根	494.91	584.00	567.49	356.38	262.22	2265.00	03_箱根	93.09	-56.00	-15.49	-21.38	-0.22	0.00	03_箱根	17.51	5.37	0.42	1.28	0.00	24.59
04_道後	497	498	429	290	203	1917	04_道後	418.87	494.28	480.30	301.63	221.93	1917.00	04_道後	78.13	3.72	-51.30	-11.63	-18.93	0.00	04_道後	14.57	0.03	5.48	0.45	1.62	22.14
05_湯布院	643	518	524	331	290	2306	05_湯布院	503.87	594.57	577.76	362.83	266.97	2306.00	05_湯布院	139.13	-76.57	-53.76	-31.83	23.03	0.00	05_湯布院	38.42	9.86	5.00	2.79	1.99	58.06
06_札幌	252	453	444	297	192	1638	06_札幌	357.91	422.34	410.39	257.73	189.63	1638.00	06_札幌	-105.91	30.66	33.61	39.27	2.37	0.00	06_札幌	31.34	2.23	2.75	5.98	0.03	42.33
07_名古屋	251	455	450	261	209	1626	07_名古屋	355.28	419.24	407.39	255.84	188.24	1626.00	07_名古屋	-104.28	35.76	42.61	5.16	20.76	0.00	07_名古屋	30.61	3.05	4.46	0.10	2.29	40.51
08_東京	179	421	439	253	212	1504	08_東京	328.63	387.79	376.82	236.64	174.12	1504.00	08_東京	-149.63	33.21	62.18	16.36	37.88	0.00	08_東京	68.13	2.84	10.26	1.13	8.24	90.60
09_大阪	254	459	525	287	203	1728	09_大阪	377.57	445.54	432.94	271.89	200.05	1728.00	09_大阪	-123.57	13.46	92.06	15.11	2.95	0.00	09_大阪	40.44	0.41	19.57	0.84	0.04	61.31
10_福岡	206	431	446	294	194	1571	10_福岡	343.27	405.06	393.61	247.19	181.88	1571.00	10_福岡	-137.27	25.94	52.39	46.81	12.12	0.00	10_福岡	54.89	1.66	6.97	8.87	0.81	73.20
合計	4105	4844	4707	2956	2175	18787	合計	4105.00	4844.00	4707.00	2956.00	2175.00	18787.00	合計	0.00	0.00	0.00	0.00	0.00	0.00	合計	404.67	25.55	80.73	35.54	28.63	575.11

2次元で可視化する: 特異値分解

- 特異値分解 $X = USV^T$




- S の特異値が小さいものを削る




2次元で可視化する: 特異値分解


● 特異値分解 $X = USV^T$



● S の特異値が小さいものを削る



- 対応分析は、カイ2乗値を利用して、関係の強さを強調して表現できる



演習用の教材 — Google Colab ノートブック

- URL: <https://github.com/haradatm/lecture-gssm2026>

haradatm/lecture-gssm2026

README MIT license

lecture-gssm2026

This repository will be used for courses 01KA438 and 0ADM126 offered in 2026.

Tutorial notebooks

Notebook	Description	Colab Link
day 2.ipynb	Text Analysis (1)	Open in Colab
day 3-1.ipynb	Text Analysis (2)	Open in Colab
day 3-2.ipynb	Text Mining (1)	Open in Colab
day 4.ipynb	Text Mining (2)	Open in Colab

Project Structure

```
├── README.md
```

describe this project

Releases

No releases published
[Create a new release](#)

Packages

No packages published
[Publish your first package](#)

Contributors 1

haradatm Tomohiko HARADA

Jupyter Notebook 94.9%
Python 4.8% Shell 0.3%

Suggested workflows

Based on your tech stack

Python application [Configure](#)

「day-3-1.ipynb」の右隣にある「Open in Colab」をクリックして開く

- 個人ワーク (~19:40 ※休憩込み)
 - ノートブック **day-3-1.ipynb** の末尾にある「**【演習】2022~2023 データセット**」に従って、別のデータセット (rakuten-1000-**2022-2024.xlsx.zip**) で作図した「**共起ネットワーク図**」と「**対応分析プロット**」を作成する

テキスト分析 (1)

使用するテキスト分析手法

● 主に以下の5種類の分析や可視化手法を利用します

分析・可視化手法	特徴	用途
ワードクラウド	テキスト内で頻出する単語を視覚的に表示する手法。単語の頻度に応じて文字の大きさや色が変わる。	テキスト全体の傾向やキーワードを直感的に把握するために使用する。プレゼンテーション資料などでの視覚的な効果も高い。
共起ネットワーク	単語の共起関係(同時に出現する関係)をネットワーク図として表現する手法。ノードが単語をエッジが共起関係を示す。	単語同士の関係性やパターンを分析するために使用する。テキスト内のトピックやテーマの繋がりを理解するために役立つ。
係り受けネットワーク	文中の単語の係り受け関係を視覚化する手法。名詞と形容詞の修飾関係をネットワークで表示する。	文の論理構造や詳細な意味関係を考慮して分析したい場合に使用する。
対応分析プロット	質的データ間の関係を可視化する手法。行列形式のデータを低次元に縮約してプロットする。	外部変数と単語の関連性や相関を調べる際に使用する。
トピックモデル	大量の文書から潜在的なトピックを自動的に抽出する手法。LDA (潜在的ディレクリ分布) アルゴリズムを使用。	大量のテキストデータから主要なトピックを特定するために使用する。ワードクラウドでプロットすることで視覚的な効果も高い。

● ワードクラウド

特徴: テキスト内で頻出する単語を視覚的に表示する手法。
単語の頻度に応じて文字の大きさや色が変わる。

用途: テキスト
プレ
共通する注目ポイントが
分かる
直感的
概念的な交
注目ポイントがカテゴリ
ズレに思えることが分かる

分析例: 宿泊者 注目ポイントを見つける、○○○○



~~全データのワードクラウド~~



~~「A レジュー」のワードクラウド~~



~~「B ビジネス」のワードクラウド~~

● 共起ネットワーク

特徴: 単語の共起関係(同時に出現する関係)をネットワーク図として表現する手法。
ノードが単語をエッジが共起関係を示す。

用途: 単語同士の関係性やハッシュタグの分析のために使用する。
テキスト内のトピックやテーマの繋がりを理解するために役立つ。


分析例①: 宿泊者の注目のポイントや評価を調べる、○○ごとに比較する

部屋に対する評価

温泉や夕食に対する評価



立地に対する評価

部屋に対する評価



全データの係り受けネットワーク図

分析例②: 宿泊者の注目ポイントを見つける、〇〇ごとに比較する




● 係り受けネットワーク

特徴: 文中の単語の係り受け関係を視覚化する手法。
名詞と形容詞の修飾関係をネットワークで表示する。

用途: 文の論理構造や詳細な意味関係を
考慮して分析したい場合に使用する。

分析例: 宿泊者の注目ポイントに対する評価を
調べる、○○ごとに比較する
(「共起ネットワーク」と同じ)

- 有向グラフのため、関係の向きまで確認できる
- 正確な関連性が表現できる一方で共起頻度が減少し、共起パタンが現れにくい



全データの係り受けネットワーク図

● 対応分析プロット

特徴: 質的データ間の関係を可視化。行列形式のデータを低次元プロットする。

用途: 外部変数と単語の関連性や相関を調べる際に使用する。

分析例: 対照的な2エリアを見つけて、両者の違いを比較する

第2固有値までの累積寄与率は $84.52 + 7.19 = 91.7\%$ で非常に高く、第1,2固有値に対応する軸のみを分析すればよい

横軸は「カテゴリー」で寄与率86%で支配的


原点から遠い方が特徴的 (例: バイキングと登別は関連が強い)

原点付近は特徴がない

縦軸は...寄与率7%なので参考程度

低評価?

高評価?



全データの対応分析プロット

● トピックモデル

特徴: 大量の文書から潜在的なトピックを自動的に抽出する手法。LDA (潜在的ディレクリ分布) アルゴリズムを使用。※線形判別分析のLDAとは全く別もの

用途: 大量のテキストデータから主要なトピックを抽出するために使用する。ワードクラウドでプロットすることで視覚的な効果も高い

分析例: 宿泊者の注目トピック(=注目単語の集まり)を自動抽出する、〇〇ごとにトピックの出現割合を比較する

各トピックが含まれる割合も算出できる

接客と宿泊満足度




Topic # 4:

家族旅行と宿泊体験



Topic # 5:

施設老朽化への不満



Topic # 6:



立地利便性と客室品質



食事・バイキングの高評価




価格とコスパの満足感

● ChatGPT を使ってトピックを説明する

Topic	トピックワード (出現確率 Top20)	トピックの説明 (トピックワードからChatGPTで生成)
# 1	スタッフ 良い丁寧だ 宿 風呂 部屋 素晴らしい 親切だ 美味しい 素敵だ 気持ち良い 方々 温度 大変だ 女性 アウト 雰囲気 感じ 凄い 静かだ	接客と温泉の満足 スタッフの丁寧で親切な接客が高く評価されており、温泉や部屋、食事を含めた宿泊体験全体への満足度が高い。
# 2	風呂 大変だ 部屋 子供 良い 家族 美味しい ありがたい プラン 宿 サウナ 広い 綺麗だ 快適だ 夕食 外 気持ち良い 楽しい コーヒー 清潔だ	家族旅行と宿泊体験 家族連れでの利用が多く、広く清潔な部屋や風呂、食事などが快適な滞在につながっている。
# 3	部屋 残念だ 良い 風呂 宿 古い スタッフ 気 感じ 無い 狭い 人 トイレ 他 悪い 綺麗だ 建物 非常だ 普通だ 立地	施設老朽化への不満 立地や風呂などは評価される一方で、建物の古さや部屋・トイレなど設備面への不満も見られる。
# 4	部屋 良い 便利だ 駅 立地 近い 綺麗だ 快適だ コンビニ 宿 広い 清潔だ 徒歩 風呂 バス アメニティ 安い ベッド 場所 荷物	立地利便性と客室品質 駅やコンビニに近い便利な立地に加え、清潔で快適な客室環境が評価されている。
# 5	美味しい 風呂 最高 バイキング 良い 部屋 夕食 食事 種類 多い 綺麗だ 宿 広い 豊富だ 量 凄い 気持ち良い 人 楽しい 他	食事・バイキングの高評価 バイキングや夕食の美味しさ、豊富なメニューや十分な量が宿泊客から高く評価されている。
# 6	価格 安い 宿 嬉しい 良い 高い 部屋 風呂 無料 静かだ 場所 立地 広い 十分だ バス 自分 機会 凄い 雰囲気 必要だ	価格とコスパの満足感 宿泊料金の手頃さや無料サービスへの満足度が高く、価格に対する価値が評価されている。

● トピックモデル (続き)

分析例: 宿泊者の注目ポイントを見つける、〇〇ごとにトピック出現割合を比較する



「#1 接客と温泉の満足」 「#2 家族旅行と宿泊体験」 「#3 施設老朽化への不満」
「#4 立地利便性と客室品質」 「#5 食事・バイキングの高評価」 「#6 価格とコスパの満足感」

- URL: <https://github.com/haradatm/lecture-gssm2026>

The screenshot shows the GitHub repository page for 'haradatm/lecture-gssm2026'. The repository description states it will be used for courses 01KA438 and 0ADM126 offered in 2026. Under the 'Tutorial notebooks' section, there is a table with the following data:

Notebook	Description	Colab Link
day 2.ipynb	Text Analysis (1)	Open in Colab
day 3-1.ipynb	Text Analysis (2)	Open in Colab
day 3-2.ipynb	Text Mining (1)	Open in Colab
day 4.ipynb	Text Mining (2)	Open in Colab

A red box highlights the 'Open in Colab' link for 'day 3-2.ipynb', with a red arrow pointing to it from a text box. The text box contains the instruction: 「day 3-2.ipynb」の右隣にある「Open in Colab」をクリックして開く.

On the right side of the repository page, there are sections for 'Releases' (No releases published), 'Packages' (No packages published), and 'Contributors' (1). At the bottom right, there is a 'Suggested workflows' section based on the tech stack: Jupyter Notebook 94.9%, Python 4.8%, and Shell 0.3%.

day 3 – レポート課題

- 以下を PDF ファイルで提出 してください
 - ノートブック **day-3-1.ipynb** の末尾にある「【演習】2023~2024 データセット」に従って、別のデータセット (rakuten-1000-2023-2024.xlsx.zip) で作図した「共起ネットワーク図」と「対応分析プロット」のキャプチャ

※ 何らかの事情で上記のキャプチャを提出できない場合、本日の講義の感想を文章で記述してください

レポート形式	提出先	期限
PDF	manaba	次回～18:20